

빅데이터분석프로젝트 기획서

20241519 조예성 | 최초 작성: 2026-05-29 | 최종 수정: 2026-05-29

프로젝트 문제정의

1. 선택한 데이터

- 소방청_구급출동현황 (소방안전빅데이터플랫폼) — CSV (UTF-8), 연간 약 48~62만 행, 92개 컬럼. 라이선스: 공공데이터(출처별 라이선스 확인 필요).
- 소방청_구급상황관리현황 (소방안전빅데이터플랫폼) — CSV (UTF-8), 연간 약 130~170만 행, 26개 컬럼. 라이선스: 공공데이터(출처별 라이선스 확인 필요).
- 서울시 소방서·안전센터 위치 정보 (서울열린데이터광장) — CSV (UTF-8), 좌표 포함(일부 TM 변환 필요).
- 소방청_전국소방서 좌표현황 (공공데이터포털) — CSV (CP949), WGS84 좌표 제공.
- 소방청_119신고 전화 유형, 주소별 집계 등 보조 데이터 — CSV/XLSX, 인코딩 혼재(CP949/UTF-8).
- E-Gen 응급의료정보 API (중앙응급의료센터) — 실시간 REST API, 병상·중증수용 가능 여부 등 제공 (API 키 필요).

2. 풀고 싶은 문제

- "구급출동 이력 데이터와 E-Gen 실시간 병상/병원 정보를 이용해, 사용자의 GPS와 증상으로 적합한 소방서(안전센터)와 병원을 즉시 추천하고 싶다."
- 예측/분류 대상(Target): 추천 대상(최적 소방서/안전센터 및 병원) — 상위 N개(예: TOP-3) 순위화.

3. 만들 서비스(완성 모습)

- 입력: 사용자 위치(GPS 위도·경도), 증상 선택(드롭다운), 선택적 환자 정보(연령대·중증도 추정).
- 출력: 추천 소방서(안전센터) TOP-3, 추천 병원 TOP-3(거리·실시간 병상·전문진료 가능여부 기반 점수 및 간단 설명). 지도 마커와 추천 카드 제공.
- 모델/기술 스택 선택: 주로 ML(거리·병상·증상 기반 점수화 및 랭킹 알고리즘)이며, 사용자 설명과 자유 질의응답을 위해 LLM 보조(챗봇) 사용.

4. 예상 난관 (우선 순위 1)

- 이송 목적지(병원) 정보의 부재와 시간 관련 컬럼(시·분) 전부 결측: 실제 이송 경로·소요시간 또는 추천 정답(label)을 만들기 어려워 추천 모델의 검증과 학습 라벨링이 제한된다. (대응: E-Gen 실시간 데이터로 후검증, 부분 라벨링·휴리스틱 기반 평가 도입)

1. 프로젝트 개요

1-1. 주제

서울시 구급 출동 데이터 기반 응급환자 소방서·병원 추천 서비스

구급 출동 이력 데이터(2017~2022)와 응급의료기관 실시간 API를 결합하여, GPS 위치와 증상을 입력하면 **어느 119 안전센터에서 출동하고 어느 병원으로 가는 것이 가장 효율적인지** 추천하는 Streamlit 서비스를 제작한다. 아울러 구급 출동 현황, 2차 이송(뺑뺑이) 실태, 증상 분포 등을 시각화한 분석 대시보드를 함께 제공한다.

1-2. 기대 효과

대상	기대 효과
일반 시민	GPS + 증상 입력만으로 최적 소방서·병원 즉시 확인
정책 입안자	구·동별 출동 밀도, 2차 이송 다발 지역 → 의료시설 확충 근거
소방·구급 당국	안전센터별 출동 패턴 분석 → 자원 배치 최적화

2. 데이터

2-1. 데이터 목록

#	데이터명	출처	기간	형식	인코딩	상태
1	소방청_구급출동현황	소방안전빅데이터플랫폼	2017–2022	CSV	UTF-8	✓ 보유
2	소방청_구급상황관리현황	소방안전빅데이터플랫폼	2019–2023	CSV	UTF-8	✓ 보유
3	서울시 소방 구급 출동 현황	서울열린데이터광장	2022–2024	XLSX	—	✓ 보유
4	소방청_119신고 전화 유형	공공데이터포털	2011–2023	CSV	CP949	✓ 보유
5	소방청_서울 주소별 구급출동 현황	공공데이터포털	2019	CSV	CP949	✓ 보유
6	소방청_전국소방서 좌표현황	소방청 공공데이터	2024-09	CSV	CP949	✓ 보유
7	서울시 소방서·안전센터 위치 정보	서울열린데이터광장	—	CSV	UTF-8	✓ 보유
8	전국 응급의료정보조회 API	중앙응급의료센터 E-Gen	실시간	REST API	—	✓ 키 발급 완료

~~내 손안의 응급실 크롤링~~ → **E-Gen API로 대체** (실시간 병상정보 직접 제공)

2-2. 데이터 탐색 결과 요약

구급출동 데이터 (구급출동_YYYY.csv, 2017–2022)

항목	내용
규모	연간 ~48–62만 행, 92개 컬럼
지역	서울 전용 데이터 (GRNDS_CTPV_NM 99.8% 서울) — 별도 필터링 불필요
시간 컬럼	DCLR_TM, _HR, _MN 등 시·분 컬럼 100% null → 소요시간 계산 불가
날짜 컬럼	DCLR_YMD, DCLR_MM, DCLR_DOW, SEASN_NM 등 정상

항목	내용
이송병원명	컬럼 없음 (PTN_CR_NM은 환자 직업명) → API로 대체
소방서명	FRSTN_NM (null 0%, 서울 25개 소방서)
안전센터명	CNTR_NM (현장대응단·역삼119안전센터 등 파출소 단위)
사고 GPS	DAMG_RGN_LAT, DAMG_RGN_LOT (null 0%, WGS84)
증상	PTN_SYM_SE_NM (null 33%), PTN_OCRN_TYPE_NM (null 0%)
2차 이송	TRANS2_RSN (비null 0.2% = 뺑뺑이 케이스), TRANS_CLSF_RSN (이송거부 포함)

구급상황관리 데이터 (구 급 상 황 관 리 현 황 _ Y Y Y Y _ 전 국 . csv, 2019–2023)

항목	내용
규모	연간 ~130–170만 행, 26개 컬럼
지역	전국 (서울 약 19%)
시간 컬럼	MDLCR_DSCSN_BGNG_HR/MN, END_HR/MN 정상 → 의료지도 소요시간 계산 가능
주증상	MAIN_SYM_NM (null 57%, 발열·고열·의식기능저하 순)
중증도	SRIL_CLSF_NM (null 67%, 비응급·응급·긴급 순)

소방서·안전센터 위치 데이터

파일	내용	좌표계	서울 수량
소방청_전국소방서 좌표현황.csv	소방서 215개 + 안전센터 1001개 (전국)	WGS84 (바로 사용 가능)	소방서 24 + 안전센터 113
서울시 소방서, 안전센터, 구조대 위치 정보.csv	소방서 25 + 안전센터/구조대 155 (서울)	TM좌표 (변환 필요)	전체 180

주의: **CNTR_NM**의 이름 형식(**역삼119안전센터**)과 좌표 파일의 이름 형식(**강남소방서-역삼-119 안전센터**) 이 달라 전처리 시 매핑 작업 필요

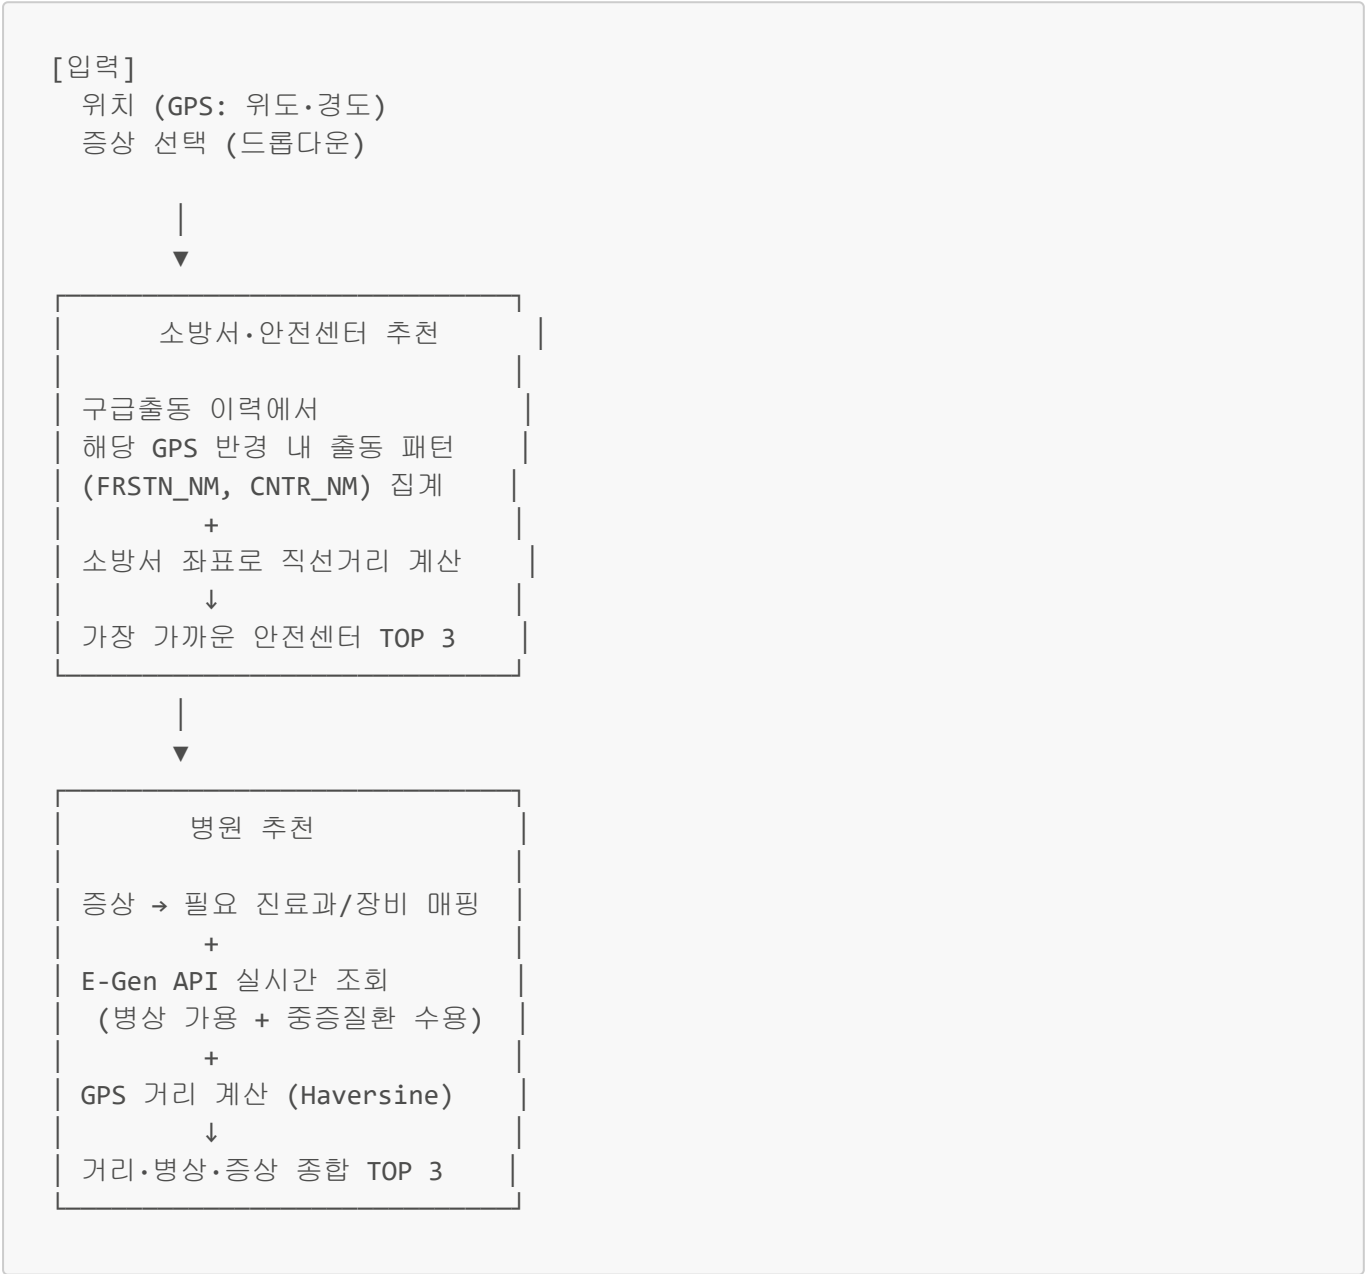
E-Gen API (실시간)

오퍼레이션	제공 정보	활용
getEmrrmRltnUsefulSckbdInfoInquire	실시간 병상(일반·중환자실), CT/MRI/ECMO 가용	병원 추천 핵심
getSrsillDissAceptncPosblInfoInquire	뇌졸중·심정지·외상 등 중증질환 수용 가능 여부	중증 증상 추천
getEgytListInfoInquire	병원 목록 + GPS(wgs84Lat/Lon)	병원 좌표 수집

오퍼레이션	제공 정보	활용
getEgytBassInfoInquire	진료과목, 응급실 전화 등 기본정보	병원 상세 정보
상세 명세: API_응급의료정보.md		

3. 핵심 서비스: 소방서·병원 추천

3-1. 추천 로직



3-2. 증상 → 병원 필드 매핑

증상 그룹	PTN_SYM_SE_NM 값	우선 확인 API 필드
심장	흉통, 심계항진	MKioskTy3/4 (심근경색), hvicc, hvectoayn
뇌	의식저하, 두통, 편측마비	MKioskTy1/2 (뇌출혈/경색), hvcc, hvctayn

증상 그룹	PTN_SYM_SE_NM 값	우선 확인 API 필드
외상	교통사고, 낙상, 추락	MKioskTy19 (중증외상), hv9, 외상센터
호흡	호흡곤란, 호흡정지	hvventiayn, hvicc, hvec
화상	화상	MKioskTy11/12
소아	소아 관련	MKioskTy15, hvncc
일반/기타	기타통증, 복통, 고열 등	hvec (응급실 일반병상)

4. 분석 대시보드

4-1. 페이지 구조

app/ ├── Home.py └── pages/ ├── 1_추천_서비스.py ├── 2_출동현황_분석.py ├── 3_뽕뽕이_분석.py ├── 4_증상별_분석.py ├── 5_신고유형_추세.py └── 6_AI_챗봇.py	# 프로젝트 소개, 데이터 요약 KPI # ★ 핵심: GPS + 증상 → 소방서·병원 추천 # 연도·월·요일별 출동 추이, 구·동별 지도 # 2차 이송 발생률, 이송거절 사유 분포 # 증상 빈도 TOP 20, 중증도 분포 # 119 신고 유형 2011-2023 추이 # GPT 기반 분석 결과 해설
--	--

4-2. 페이지별 핵심 컴포넌트

페이지	주요 시각화	핵심 인터랙션
Home	데이터 규모 메트릭 카드, 서비스 소개	—
추천 서비스	지도 위 소방서·병원 마커, 추천 카드	GPS 입력/지도 클릭, 증상 선택
출동현황 분석	연도별 라인차트, 구별 choropleth, 시간대 히트맵	연도·구 필터
뽕뽕이 분석	2차 이송률 추이, 이송거절 사유 가로 막대	연도 슬라이더
증상별 분석	주증상 TOP 20, 중증도 파이, 의료지도 소요시간	연도·지역 필터
신고유형 추세	스택 영역 차트 (화재/구급/구조/기타)	기간 슬라이더
AI 챗봇	st.chat_message 채팅 UI	자유 질문 입력

4-3. AI 챗봇 설계

- **모델:** OpenAI GPT-4o (OPENAI_API_KEY)
- **System Prompt:** 분석 결과 요약 + 추천 서비스 결과를 context로 주입 → 일반인 눈높이 해설
- **주요 질문 예시:**
 - "지금 제 위치에서 가장 가까운 응급실이 어디예요?"
 - "흉통이 있을 때 어느 병원으로 가야 해요?"
 - "구급차 뽕뽕이가 가장 많이 발생한 구는 어디예요?"

5. 프로젝트 구조

```

BigdataAnalysis-project/
├── app/                                # Streamlit 앱
│   ├── Home.py
│   ├── pages/
│   │   ├── 1_추천_서비스.py
│   │   ├── 2_출동현황_분석.py
│   │   ├── 3_뽕뽕이_분석.py
│   │   ├── 4_증상별_분석.py
│   │   ├── 5_신고유형_추세.py
│   │   └── 6_AI_챗봇.py
│   └── components/
│       ├── charts.py                # 재사용 plotly 차트
│       └── maps.py                  # 지도 컴포넌트 (folium/pydeck)
├── src/
│   ├── config.py                    # 경로·데이터셋·컬럼 메타 설정
│   ├── data/
│   │   ├── loader.py                # 청크 로딩, Parquet 캐시
│   │   └── preprocess.py            # 정제·파생 컬럼 생성, 안전센터명 매핑
│   ├── analysis/
│   │   ├── dispatch.py              # 출동 패턴 집계 (소방서 추천용)
│   │   ├── regional.py              # 지역별 집계
│   │   └── symptom.py               # 증상별 집계
│   └── recommend/
│       ├── station.py               # 119 안전센터 추천 로직
│       └── hospital.py              # 병원 추천 로직 (E-Gen API 연동)
├── notebooks/
│   ├── 01_eda_출동데이터.ipynb
│   ├── 01_eda_상황관리데이터.ipynb
│   ├── 02_analysis_출동패턴.ipynb
│   ├── 02_analysis_뽕뽕이.ipynb
│   └── 02_analysis_증상분석.ipynb
├── data/                              # git 추적 제외
│   ├── 구급출동현황/                 # CSV 2017-2022 (서울)
│   ├── 구급상황관리현황/             # CSV 2019-2023 (전국)
│   ├── 소방청_전국소방서 좌표현황(XY좌표)_20240901.csv
│   ├── 서울시 소방서, 안전센터, 구조대 위치 정보.csv
│   ├── 서울시 소방 구급 출동 현황(2022_2024).xlsx
│   ├── 소방청_119신고 전화 유형_20231231.csv
│   ├── 소방청_서울특별시 주소별 구급출동현황_20191231.csv
│   ├── interim/                     # 중간 가공물
│   └── processed/                   # 집계 결과 Parquet
├── docs/
│   ├── 기획서.md
│   └── API_응급의료정보.md          # E-Gen API 레퍼런스

```

└─ Api문서.pdf	# 원본 API 문서
└─ .env	# API 키 (git 제외)
└─ .env.example	
└─ .gitignore	
└─ requirements.txt	
└─ README.md	

6. 기술 스택

영역	라이브러리	버전
데이터 처리	pandas, numpy, pyarrow	2.3 / 2.0 / 21
파일 입출력	openpyxl, tqdm	3.1 / 4.67
시각화	plotly, matplotlib, seaborn	6.7 / 3.9 / 0.13
지도	folium, pydeck, streamlit-folium	0.20 / 0.9 / 0.25
웹 앱	streamlit	1.50
AI 챗봇	openai (GPT-4o)	—
API 연동	requests, python-dotenv	2.32 / 1.2
개발 환경	Python 3.9.12, .venv	—

7. 개발 단계

단계	내용	산출물
1단계 ☒	데이터 탐색 · EDA · API 확인	탐색 결과 정리 (본 기획서)
2단계	전처리 파이프라인	안전센터명 매핑, Parquet 변환, src/data/
3단계	주제별 분석	출동패턴·뽕뽕이·증상 분석, notebooks/02_*
4단계	추천 서비스 구현	src/recommend/, E-Gen API 연동
5단계	대시보드 구현	Streamlit 6개 페이지, app/
6단계	AI 챗봇 연동	GPT-4o + context 주입, app/pages/6_AI_챗봇.py
7단계	최종 검토·정리	README 보완, 발표 자료

8. 주요 고려사항

데이터 제약

- 시간 컬럼 결측: 구급출동 데이터의 _TM, _HR, _MN 컬럼이 전 연도에 걸쳐 100% null → 이송 소요시간 분석 불가. 출동 건수·발생 패턴·2차 이송 여부 중심으로 분석 재설계

- **이송 병원명 없음:** 구급출동 데이터에 목적지 병원 정보가 없음 → E-Gen API 실시간 데이터로 병원 추천

안전센터 이름 매핑

- CNTR_NM 형식: "역삼**119**안전센터"
- 좌표 파일 형식: "강남소방서-역삼-**119** 안전센터"
- 핵심 이름(역삼, 잠실 등) 추출 후 fuzzy matching 또는 수작업 매핑 딕셔너리 필요

대용량 데이터 처리

- 연간 CSV 200~310MB, 6년치 합계 ~1.3GB → 청크 처리 후 집계 결과만 Parquet으로 저장
- Streamlit은 `data/processed/`의 Parquet만 읽음 (`@st.cache_data` 적용)

API 키 관리

- `EMER_API_KEY` (E-Gen), `OPENAI_API_KEY` → `.env`에 보관, git 추적 제외
- 키는 `.env.example`에 변수명만 명시